

Manipulação e Visualização de Dados

a abordagem tidyverse

Prof. Walmes Zeviani
walmes@ufpr.br

Laboratório de Estatística e Geoinformação
Departamento de Estatística
Universidade Federal do Paraná

Motivação

Manipulação e visualização de dados

- ▶ Manipular e visualizar dados são tarefas **obrigatórias** em Data Science (DS).
- ▶ O conhecimento sobre dados **determina o sucesso** das etapas seguintes.
- ▶ Fazer isso de forma eficiente requer:
 - ▶ Conhecer o processo e suas etapas.
 - ▶ Dominar a tecnologia para isso.
- ▶ Existem inúmeros softwares voltados para isso.
- ▶ R se destaca em DS por ser *free & open source*, ter muitos recursos e uma ampla comunidade.

O tempo gasto em DS

O que os cientistas de dados mais gastam tempo fazendo e como gostam disso?





Figura 1. Tempo gasto e diversão em atividades. Fonte: Gil Press, 2016.

O ambiente R para manipulação de dados

- ▶ O R é a língua franca da Estatística.
- ▶ Desde o princípio oferece recursos para manipulação de dados.
 - ▶ O `data.frame` é a estrutura base para dados tabulares.
 - ▶ `base`, `utils`, `stats`, `reshape`, etc com recursos para importar, transformar, modificar, filtrar, agregar, `data.frames`.
- ▶ Porém, existem “algumas imperfeições” ou espaço para melhorias:
 - ▶ Coerções indesejadas de `data.frame`/matriz para vetor.
 - ▶ Ordem/nome irregular/inconsistente dos argumentos nas funções.
 - ▶ Dependência de pacotes apenas em cascata.

A faint, grayscale watermark-style image of a classical building's facade, featuring columns and architectural details, serves as the background for the slide.

A abordagem tidyverse

O tidyverse

- ▶ Oferece uma **reimplementação e extensão** das funcionalidades para manipulação e visualização.
- ▶ É uma coleção **8 de pacotes R** que operam em harmonia.
- ▶ Eles foram planejados e construídos para trabalhar em conjunto.
- ▶ Possuem gramática, organização, filosofia e estruturas de dados mais clara.
- ▶ Maior facilidade de desenvolvimento de código e portabilidade.
- ▶ Outros pacotes acoplam muito bem com o tidyverse.
- ▶ Pacotes: <https://www.tidyverse.org/packages/>.
- ▶ R4DS: <https://r4ds.had.co.nz/>.
- ▶ Cookbook: <https://rstudio-education.github.io/tidyverse-cookbook/program.html>.

O que o tidyverse contém

```
library(tidyverse)
ls("package:tidyverse")
```

1

2

```
## [1] "tidyverse_conflicts" "tidyverse_deps"      "tidyverse_logo"
## [4] "tidyverse_packages"   "tidyverse_update"
```

```
tidyverse_packages()
```

1

```
##  [1] "broom"        "cli"          "crayon"       "dplyr"
##  [5] "dbplyr"       "forcats"      "ggplot2"      "haven"
##  [9] "hms"          "httr"         "jsonlite"     "lubridate"
## [13] "magrittr"     "modelr"       "purrr"        "readr"
## [17] "readxl\n(>=" "reprex"      "rlang"        "rstudioapi"
## [21] "rvest"        "stringr"     "tibble"       "tidyr"
## [25] "xml2"         "tidyverse"
```

Os pacotes do tidyverse



Figura 2. Pacotes que fazem parte do tidyverse.

Mas na realidade



Figura 3. Em um universo pararelo.

A anatomia do tidyverse

tibble

- ▶ Uma reimplementação do `data.frame` com muitas melhorias.
- ▶ Método `print()` enxuto.
- ▶ Documentação: <https://tibble.tidyverse.org/>.

readr

- ▶ Leitura de dados tabulares: `csv`, `tsv`, `fwf`.
- ▶ Recursos “inteligentes” que determinam tipo de variável.
- ▶ Ex: importar campos de datas como datas!
- ▶ Documentação: <https://readr.tidyverse.org/>.

A anatomia do tidyverse

tidyverse

- ▶ Suporte para criação de dados no formato tidy (tabular).
 - ▶ Cada variável está em uma coluna.
 - ▶ Cada observação (unidade amostral) é uma linha.
 - ▶ Cada valor é uma cédula.
- ▶ Documentação: <https://tidyverse.org/>.

dplyr

- ▶ Oferece uma gramática extensa pra manipulação de dados.
- ▶ Operações de *split-apply-combine*.
- ▶ Na maior parte da manipulação é usado o dplyr.
- ▶ Documentação: <https://dplyr.tidyverse.org/>.

A anatomia do tidyverse

ggplot2

- ▶ Criação de gráficos baseado no *The Grammar of Graphics* (WILKINSON et al., 2013).
- ▶ Claro mapeamento das variáveis do BD em variáveis visuais e construção baseada em camadas.
- ▶ Documentação: <https://ggplot2.tidyverse.org/>.
- ▶ WICKHAM (2016): ggplot2 - Elegant Graphics for Data Analysis.
- ▶ TEUTONICO (2015): ggplot2 Essentials.

forcats

- ▶ Para manipulação de variáveis categóricas/fatores.
 - ▶ Renomenar, reordenar, transformar, aglutinar.
- ▶ Documentação: <https://forcats.tidyverse.org/>.

A anatomia do tidyverse

stringr

- ▶ Recursos coesos construídos para manipulação de *strings*.
- ▶ Feito sobre o stringi.
- ▶ Documentação: <https://stringr.tidyverse.org/>.

purrr

- ▶ Recursos para **programação funcional**.
- ▶ Funções que aplicam funções em lote varrendo objetos: vetores, listas, etc.
- ▶ Documentação: <https://purrr.tidyverse.org/>.

Harmonizam bem com o tidyverse

- ▶ `magrittr`: operadores *pipe* → `%>%`.
- ▶ `rvest`: *web scraping*.
- ▶ `httr`: requisições HTTP e afins.
- ▶ `xml2`: manipulação de XML.
- ▶ `lubridate` e `hms`: manipulação de dados cronológicos.

Estruturas de dados do tibble

Anatomia do tibble

- ▶ Aperfeiçoamento do `data.frame`.
- ▶ A classe `tibble`.
- ▶ Formas ágeis de criar `tibbles`.
- ▶ Formas ágeis de modificar objetos das classes.
- ▶ Método `print` mais enxuto e informativo.

```
# packageVersion("tibble")
ls("package:tibble")
```

1

2

```
## [1] "add_case"                 "add_column"
## [3] "add_row"                  "as_data_frame"
## [5] "as_tibble"                "as.tibble"
## [7] "column_to_rownames"       "data_frame"
## [9] "data_frame_"              "deframe"
## [11] "enframe"                  "frame_data"
## [13] "frame_matrix"             "glimpse"
## [15] "has_name"                 "has_rownames"
## [17] "is_tibble"                "is.tibble"
## [19] "is_vector_s3"            "knit_print.trunc_mat"
## [21] "lst"                      "lst_"
## [23] "new_tibble"               "obj_sum"
## [25] "remove_rownames"          "repair_names"
## [27] "rowid_to_column"          "rownames_to_column"
## [29] "set_tidy_names"           "tbl_sum"
## [31] "tibble"                   "tibble_"
## [33] "tidy_names"               "tribble"
## [35] "trunc_mat"                "type_sum"
```


A faint, grayscale watermark-like image of a classical building's facade, featuring multiple columns and architectural details, serves as the background for the slide.

Leitura de dados com readr

Anatomia do readr

- ▶ Importação de dados no formato texto.
 - ▶ Funções de importação: `read_*`().
 - ▶ Funções de escrita: `write_*`().
 - ▶ Funções de *parsing*: `parse_*`.
- ▶ Conseguem identificar campos de data.
- ▶ Muitas opções de controle de importação:
 - ▶ Encoding.
 - ▶ Separador de campo e decimal.
 - ▶ Aspas, comentários, etc.
- ▶ Cartão de leitura com o `readr` e arrumação com o `tidyR`: <https://rawgit.com/rstudio/cheatsheets/master/data-import.pdf>.
- ▶ Exemplos do curso de leitura de dados com o `readr`:
<http://leg.ufpr.br/~walmes/cursoR/data-vis/99-datasets.html>.

```
# packageVersion("readr")
ls("package:readr") %>%
  str_subset("(read|parse|write)_") %>%
  sort()

## [1] "parse_character"      "parse_date"           "parse_datetime"
## [4] "parse_double"         "parse_factor"        "parse_guess"
## [7] "parse_integer"        "parse_logical"       "parse_number"
## [10] "parse_time"          "parse_vector"        "read_csv"
## [13] "read_csv2"            "read_csv2_chunked"   "read_csv_chunked"
## [16] "read_delim"          "read_delim_chunked" "read_file"
## [19] "read_file_raw"        "read_fwf"             "read_lines"
## [22] "read_lines_chunked"  "read_lines_raw"       "read_log"
## [25] "read_rds"             "read_table"           "read_table2"
## [28] "read_tsv"              "read_tsv_chunked"    "write_csv"
## [31] "write_delim"          "write_excel_csv"     "write_file"
## [34] "write_lines"           "write_rds"            "write_tsv"
```

1
2
3
4

Data types

readr functions guess the types of each column and convert types when appropriate (but will NOT convert strings to factors automatically).

A message shows the type of each column in the result.

```
## Parsed with column specification:  
## cols(  
##   age = col_integer(),  
##   sex = col_character(),  
##   earn = col_double()  
## )
```

age is an integer
sex is a character
earn is a double (numeric)

1. Use **problems()** to diagnose problems.

```
x <- read_csv("file.csv"); problems(x)
```

2. Use a col_ function to guide parsing.

- **col_guess()** – the default
- **col_character()**
- **col_double()**, **col_euro_double()**
- **col_datetime(format = "")** Also **col_date(format = "")**, **col_time(format = "")**
- **col_factor(levels, ordered = FALSE)**
- **col_integer()**
- **col_logical()**
- **col_number()**, **col_numeric()**
- **col_skip()**

```
x <- read_csv("file.csv", col_types = cols(  
  A = col_double(),  
  B = col_logical(),  
  C = col_factor()))
```

3. Else, read in as character vectors then parse with a parse_function.

- **parse_guess()**
 - **parse_character()**
 - **parse_datetime()** Also **parse_date()** and **parse_time()**
 - **parse_double()**
 - **parse_factor()**
 - **parse_integer()**
 - **parse_logical()**
 - **parse_number()**
- ```
x$A <- parse_number(x$A)
```

Figura 7. Parsing de valores com readr.



## Dados no formato tidy com `tidyverse`

# Anatomia do tidyR

- ▶ Para fazer arrumação dos dados.
- ▶ Mudar a disposição dos dados: *long*  $\rightleftharpoons$  *wide*.
- ▶ Partir uma variável em vários campos.
- ▶ Concatenar vários campos para criar uma variável.
- ▶ Remover ou imputar os valores ausentes: NA.
- ▶ Aninhar listas em tabelas: tribble.

```
packageVersion("tidyverse")
ls("package:tidyverse")
```


```
[1] "%>%"
[4] "crossing"
[7] "drop_na_"
[10] "extract"
[13] "fill"
[16] "gather"
[19] "nest_"
[22] "population"
[25] "separate_"
[28] "smiths"
[31] "table1"
[34] "table4a"
[37] "uncount"
[40] "unnest"
[1] "complete"
[4] "crossing_"
[7] "expand"
[10] "extract_"
[13] "fill_"
[16] "gather_"
[19] "nesting"
[22] "replace_na"
[25] "separate_rows"
[28] "spread"
[31] "table2"
[34] "table4b"
[37] "unite"
[40] "unnest_"
[1] "complete_"
[4] "drop_na"
[7] "expand_"
[10] "extract_numeric"
[13] "full_seq"
[16] "nest"
[19] "nesting_"
[22] "separate"
[25] "separate_rows_"
[28] "spread_"
[31] "table3"
[34] "table5"
[37] "unite_"
[40] "who"
```



# Tidy Data with `tidyverse`

**Tidy data** is a way to organize tabular data. It provides a consistent data structure across packages.

A table is tidy if:




Each **variable** is in its own **column**

&




Each **observation**, or **case**, is in its own **row**

Tidy data:



Makes variables easy to access as vectors



Preserves cases during vectorized operations

Figura 9. A definição de *tidy data* ou formato tabular.



# Handle Missing Values

## **drop\_na**(data, ...)

Drop rows containing  
NA's in ... columns.

| X  |    |
|----|----|
| x1 | x2 |
| A  | 1  |
| B  | NA |
| C  | NA |
| D  | 3  |
| E  | NA |

`drop_na(x, x2)`

## **fill**(data, ..., .direction = c("down", "up"))

Fill in NA's in ... columns with most  
recent non-NA values.

| X  |    |
|----|----|
| x1 | x2 |
| A  | 1  |
| B  | NA |
| C  | NA |
| D  | 3  |
| E  | NA |

`fill(x, x2)`

## **replace\_na**(data, replace = list(), ...)

Replace NA's by column.

| X  |    |
|----|----|
| x1 | x2 |
| A  | 1  |
| B  | NA |
| C  | NA |
| D  | 3  |
| E  | NA |

`replace_na(x, list(x2 = 2))`

# Expand Tables - quickly create tables with combinations of values

## **complete**(data, ..., fill = list())

Adds to the data missing combinations of the  
values of the variables listed in ...

`complete(mtcars, cyl, gear, carb)`

## **expand**(data, ...)

Create new tibble with all possible combinations  
of the values of the variables listed in ...

`expand(mtcars, cyl, gear, carb)`

Figura 11. Recursos para lidar com dados ausentes do tidyR.



# Agregação com dplyr

# Anatomia do dplyr

- ▶ O dplyr é a **gramática** para manipulação de dados.
- ▶ Tem um conjunto **consistente** de verbos para atuar sobre tabelas.
  - ▶ Verbos: `mutate()`, `select()`, `filter()`, `arrange()`, `summarise()`, `slice()`, `rename()`, etc.
  - ▶ Sufixos: `_at()`, `_if()`, `_all()`, etc.
  - ▶ Agrupamento: `group_by()` e `ungroup()`.
  - ▶ Junções: `inner_join()`, `full_join()`, `left_join()` e `right_join()`.
  - ▶ Funções resumo: `n()`, `n_distinct()`, `first()`, `last()`, `nth()`, etc.
  - ▶ E muito mais no cartão de referência.
- ▶ Cartão de referência: <https://github.com/rstudio/cheatsheets/raw/master/data-transformation.pdf>.
- ▶ É sem dúvida o pacote mais importante do tidyverse.

```
library(dplyr)
ls("package:dplyr") %>% str_c(collapse = ", ") %>% strwrap()

[1] "%>%, add_count, add_count_, add_row, add_rownames, add_tally,"
[2] "add_tally_, all_equal, all_vars, anti_join, any_vars, arrange,"
[3] "arrange_, arrange_all, arrange_at, arrange_if, as_data_frame,"
[4] "as.tbl, as.tbl_cube, as_tibble, auto_copy, band_instruments,"
[5] "band_instruments2, band_members, bench_tbls, between,"
[6] "bind_cols, bind_rows, case_when, changes, check_dbplyr,"
[7] "coalesce, collapse, collect, combine, common_by, compare_tbls,"
[8] "compare_tbls2, compute, contains, copy_to, count, count_,"
[9] "cumall, cumany, cume_dist, cummean, current_vars, data_frame,"
[10] "data_frame_, db_analyze, db_begin, db_commit, db_create_index,"
[11] "db_create_indexes, db_create_table, db_data_type, db_desc,"
[12] "db_drop_table, db_explain, db_has_table, db_insert_into,"
[13] "db_list_tables, db_query_fields, db_query_rows, db_rollback,"
[14] "db_save_query, db_write_table, dense_rank, desc, dim_desc,"
[15] "distinct, distinct_, do, do_, dr_dplyr, ends_with, enexpr,"
[16] "enexprs, enquo, enquos, ensym, ensyms, eval_tbls, eval_tbls2,"
[17] "everything, explain, expr, failwith, filter, filter_,"
[18] "filter_all, filter_at, filter_if, first, frame_data, full_join,"
[19] "fun, funs_, glimpse, group_by, group_by_, group_by_all,"
[20] "group_by_at, group_by_if, group_by_prepare, grouped_df,"
[21] "group_indices, group_indices_, groups, group_size, group_vars,"
[22] "id, ident, if_else, inner_join, intersect, is_grouped_df,"
[23] "is_grouped_df, is_src, is_tbl, lag, last, lead, left_join,"
[24] "location, lst, lst_, make_tbl, matches, min_rank, mutate,"
[25] "mutate_, mutate_all, mutate_at, mutate_each, mutate_each_,"
[26] "mutate_if, n, na_if, nasa, n_distinct, near, n_groups, nth,"
[27] "ntile, num_range, one_of, order_by, percent_rank,"
[28] "progress_estimated, pull, quo, quo_name, quos, rbind_all,"
```





# Programação funcional com purrr

# Anatomia do purrr

- ▶ O purrr fornece um conjunto **completo e consistente** para **programação funcional**.
- ▶ São uma sofisticação da *família apply*.
- ▶ Várias função do tipo `map` para cada tipo de input/output.
- ▶ Percorrem vetores, listas, colunas, linhas, etc.
- ▶ Permitem filtrar, concatenar, parear listas, etc.
- ▶ Tem funções para tratamento de exceções: falhas/erros, avisos.
- ▶ Cartão de referência:  
<https://github.com/rstudio/cheatsheets/raw/master/purrr.pdf>.

```
library(purrr)
ls("package:purrr") %>% str_c(collapse = ", ") %>% strwrap()

[1] "%>%, %||%, %@%, accumulate, accumulate_right, array_branch,"
[2] "array_tree, as_function, as_mapper, as_vector, at_depth,"
[3] "attr_getter, auto_browse, compact, compose, cross, cross2,"
[4] "cross3, cross_d, cross_df, cross_n, detect, detect_index,"
[5] "discard, every, flatten, flatten_chr, flatten_dbl, flatten_df,"
[6] "flatten_dfc, flatten_dfr, flatten_int, flatten_lgl,"
[7] "has_element, head_while, imap, imap_chr, imap_dbl, imap_dfc,"
[8] "imap_dfr, imap_int, imap_lgl, invoke, invoke_map,"
[9] "invoke_map_chr, invoke_map_dbl, invoke_map_df, invoke_map_dfc,"
[10] "invoke_map_dfr, invoke_map_int, invoke_map_lgl, is_atomic,"
[11] "is_bare_atomic, is_bare_character, is_bare_double,"
[12] "is_bare_integer, is_bare_list, is_bare_logical,"
[13] "is_bare_numeric, is_bare_vector, is_character, is_double,"
[14] "is_empty, is_formula, is_function, is_integer, is_list,"
[15] "is_logical, is_null, is_numeric, is_scalar_atomic,"
[16] "is_scalar_character, is_scalar_double, is_scalar_integer,"
[17] "is_scalar_list, is_scalar_logical, is_scalar_numeric,"
[18] "is_scalar_vector, is_vector, iwalk, keep, lift, lift_dl,"
[19] "lift_dv, lift_ld, lift_lv, lift_vd, lift_vl, list_along,"
[20] "list_merge, list_modify, lmap, lmap_at, lmap_if, map, map2,"
[21] "map2_chr, map2_dbl, map2_df, map2_dfc, map2_dfr, map2_int,"
[22] "map2_lgl, map_at, map_call, map_chr, map_dbl, map_df, map_dfc,"
[23] "map_dfr, map_if, map_int, map_lgl, modify, modify_at,"
[24] "modify_depth, modify_if, negate, partial, pluck, pmap,"
[25] "pmap_chr, pmap_dbl, pmap_df, pmap_dfc, pmap_dfr, pmap_int,"
[26] "pmap_lgl, possibly, prepend, pwalk, quietly, rbernoulli,"
[27] "r dunif, reduce, reduce2, reduce2_right, reduce_right,"
[28] "rep_along, rerun, safely, set_names, simplify, simplify_all,"
```





# Gráficos com ggplot2

# Anatomia do ggplot2

- ▶ O `ggplot2` é o pacote gráfico mais adotado em ciência de dados.
- ▶ Sua implementação é baseada no *The Grammar of Graphics* (WILKINSON et al., 2013).
- ▶ A gramática faz com que a construção dos gráficos seja por camadas.
- ▶ Cartão de referência: <https://github.com/rstudio/cheatsheets/raw/master/data-visualization-2.1.pdf>.
- ▶ Um tutorial de `ggplot2` apresentado no R Day:  
[http://rday.leg.ufpr.br/materiais/intro\\_ggplot2\\_tomas.pdf](http://rday.leg.ufpr.br/materiais/intro_ggplot2_tomas.pdf).





```
u <- ls("package:ggplot2")
u %>% str_subset("^geom_")
```

1  
2

```
[1] "geom_abline" "geom_area" "geom_bar"
[4] "geom_bin2d" "geom_blank" "geom_boxplot"
[7] "geom_col" "geom_contour" "geom_count"
[10] "geom_crossbar" "geom_curve" "geom_density"
[13] "geom_density2d" "geom_density_2d" "geom_dotplot"
[16] "geom_errorbar" "geom_errorbarh" "geom_freqpoly"
[19] "geom_hex" "geom_histogram" "geom_hline"
[22] "geom_jitter" "geom_label" "geom_line"
[25] "geom_linerange" "geom_map" "geom_path"
[28] "geom_point" "geom_pointrange" "geom_polygon"
[31] "geom_qq" "geom_qq_line" "geom_quantile"
[34] "geom_raster" "geom_rect" "geom_ribbon"
[37] "geom_rug" "geom_segment" "geom_sf"
[40] "geom_sf_label" "geom_sf_text" "geom_smooth"
[43] "geom_spoke" "geom_step" "geom_text"
[46] "geom_tile" "geom_violin" "geom_vline"
```

---

```
u %>% str_subset("^theme_")
```

1

```
[1] "theme_bw" "theme_classic" "theme_dark" "theme_get"
[5] "theme_gray" "theme_grey" "theme_light" "theme_linedraw"
[9] "theme_minimal" "theme_replace" "theme_set" "theme_test"
[13] "theme_update" "theme_void"
```

```
u %>% str_subset("^stat_")
```

1

```
[1] "stat_bin" "stat_bin2d" "stat_bin_2d"
[4] "stat_binhex" "stat_bin_hex" "stat_boxplot"
[7] "stat_contour" "stat_count" "stat_density"
[10] "stat_density2d" "stat_density_2d" "stat_ecdf"
[13] "stat_ellipse" "stat_function" "stat_identity"
[16] "stat_qq" "stat_qq_line" "stat_quantile"
[19] "stat_sf" "stat_sf_coordinates" "stat_smooth"
[22] "stat_spoke" "stat_sum" "stat_summary"
[25] "stat_summary2d" "stat_summary_2d" "stat_summary_bin"
[28] "stat_summary_hex" "stat_unique" "stat_ydensity"
```

---

```
u %>% str_subset("^(scale|coord)_")
```

1

```
[1] "coord_cartesian" "coord_equal"
[3] "coord_fixed" "coord_flip"
[5] "coord_map" "coord_munch"
[7] "coord_polar" "coord_quickmap"
[9] "coord_sf" "coord_trans"
[11] "scale_alpha" "scale_alpha_continuous"
[13] "scale_alpha_date" "scale_alpha_datetime"
[15] "scale_alpha_discrete" "scale_alpha_identity"
[17] "scale_alpha_manual" "scale_alpha_ordinal"
[19] "scale_color_brewer" "scale_color_continuous"
[21] "scale_color_discrete" "scale_color_distiller"
[23] "scale_color_gradient" "scale_color_gradient2"
[25] "scale_color_gradientn" "scale_color_grey"
[27] "scale_color_hue" "scale_color_identity"
[29] "scale_color_manual" "scale_color_viridis_c"
```

# Manipulação de strings com stringr

# Anatomia do stringr

- ▶ O stringr é uma coleção de funções para operações com strings.
- ▶ Ele foi construído sobre o stringi.
- ▶ Cartão de referência:  
<https://github.com/rstudio/cheatsheets/raw/master/strings.pdf>.

```
ls("package:stringr")
```

```
[1] "%>%" "boundary" "coll"
[4] "fixed" "fruit" "invert_match"
[7] "regex" "sentences" "str_c"
[10] "str_conv" "str_count" "str_detect"
[13] "str_dup" "str_extract" "str_extract_all"
[16] "str_flatten" "str_glue" "str_glue_data"
[19] "str_interp" "str_length" "str_locate"
[22] "str_locate_all" "str_match" "str_match_all"
[25] "str_order" "str_pad" "str_remove"
[28] "str_remove_all" "str_replace" "str_replace_all"
[31] "str_replace_na" "str_sort" "str_split"
[34] "str_split_fixed" "str_squish" "str_sub"
[37] "str_sub<->" "str_subset" "str_to_lower"
[40] "str_to_title" "str_to_upper" "str_trim"
[43] "str_trunc" "str_view" "str_view_all"
[46] "str_which" "str_wrap" "word"
[49] "words"
```





# Manipulação de fatores com **forcats**



# Anatomia doforcats

- ▶ Oforcats é uma coleção de funções para operações com fatores.
- ▶ Permite renomear, reordenar, aglutinar níveis, etc.
- ▶ Cartão de referência:  
<https://github.com/rstudio/cheatsheets/raw/master/factors.pdf>.

---

```
ls("package:forcats")
```

1

```
[1] "%>%"
[4] "fct_c"
[7] "fct_drop"
[10] "fct_infreq"
[13] "fct_other"
[16] "fct_relevel"
[19] "fct_rev"
[22] "fct_unify"
[25] "last2"
[28] "lvls_revalue"
[4] "as_factor"
[7] "fct_collapse"
[10] "fct_expand"
[13] "fct_inorder"
[16] "fct_recode"
[19] "fct_reorder"
[22] "fct_shift"
[25] "fct_unique"
[28] "lvls_expand"
[4] "fct_anon"
[7] "fct_count"
[10] "fct_explicit_na"
[13] "fct_lump"
[16] "fct_relabel"
[19] "fct_reorder2"
[22] "fct_shuffle"
[25] "gss_cat"
[28] "lvls_reorder"
```



## Dados cronológicos com lubridate e hms

# Anatomia dos pacotes

- ▶ Recursos para manipulação de dados *date-time*.
- ▶ Fácil decomposição de datas: dia, mês, semana, dia da semana, etc.
- ▶ Lida com fusos horários, horários de verão, etc.
- ▶ Extende para outras classes de dados baseados em *date-time*: duração, período, intervalos.
- ▶ Cartão de referência:  
<https://rawgit.com/rstudio/cheatsheets/master/lubridate.pdf>.
- ▶ **Não** é carregado junto com o tidyverse.

```
library(lubridate)
ls("package:lubridate") %>% str_c(collapse = " ", ") %>% strwrap()

[1] "%--%, add_with_rollback, am, Arith, as_date, as_datetime,"
[2] "as.difftime, as.duration, as.interval, as.period, ceiling_date,"
[3] "Compare, date, date<-, date_decimal, day, day<-, days,"
[4] "days_in_month, ddays, decimal_date, dhours, dmicroseconds,"
[5] "dmilliseconds, dminutes, dmy, dmy_h, dmy_hm, dmy_hms,"
[6] "dnanoseconds, dpicoseconds, dseconds, dst, duration, dweeks,"
[7] "dyears, dym, edays, ehours, emicroseconds, emilliseconds,"
[8] "eminutes, enanoseconds, epicoseconds, epiweek, epiyear,"
[9] "eseconds, eweeks, eyears, fast_strptime, fit_to_timeline,"
[10] "floor_date, force_tz, force_tzs, guess_formats, here, hm, hms,"
[11] "hour, hour<-, hours, int_aligns, int_diff, int_end, int_end<-,"
[12] "intersect, interval, int_flip, int_length, int_overlaps,"
[13] "int_shift, int_standardize, int_start, int_start<-, is.Date,"
[14] "is.difftime, is.duration, is.instant, is.interval, isoweek,"
[15] "isoyear, is.period, is.POSIXct, is.POSIXlt, is.POSIXt,"
[16] "is.timepoint, is.timespan, lakers, leap_year, local_time, %m-%,"
[17] "%m+%, make_date, make_datetime, make_difftime, mday, mday<-,"
[18] "mdy, mdy_h, mdy_hm, mdy_hms, microseconds, milliseconds,"
[19] "minute, minute<-, minutes, month, month<-, ms, myd,"
[20] "nanoseconds, new_difftime, new_duration, new_interval,"
[21] "new_period, now, olson_time_zones, origin, parse_date_time,"
[22] "parse_date_time2, period, period_to_seconds, picoseconds, pm,"
[23] "pretty_dates, qday, qday<-, quarter, reclass_date,"
[24] "reclass_timespan, rollback, round_date, second, second<-,"
[25] "seconds, seconds_to_period, semester, setdiff, show, stamp,"
[26] "stamp_date, stamp_time, time_length, today, tz, tz<-, union,"
[27] "wday, wday<-, week, week<-, weeks, %within%, with_tz, yday,"
[28] "yday<-, ydm, ydm_h, ydm_hm, ydm_hms, year, year<-, years, ymd,"
```





A faint, grayscale watermark-like image of a classical building's facade, featuring columns and architectural details, serves as the background for the slide.

## Encadeando com operadores do magrittr

# Anatomia

- ▶ O operador permite expressar de forma mais direta as operações.
- ▶ É uma ideia inspirada no Shell.
- ▶ A lógica é bem simples:
  - ▶  $x \%>% f$  é o mesmo que  $f(x)$ .
  - ▶  $x \%>% f(y)$  é o mesmo que  $f(x, y)$ .
  - ▶  $x \%>% f \%>% g \%>% h$  é o mesmo que  $h(g(f(x)))$ .

# Anatomia do magrittr

```
library(magrittr)

Operadores "pipe".
ls("package:magrittr") %>%
 str_subset("%")

[1] "%<>%" "%>%" "%$%" "%T>%"
```

---

```
Outras funções/objetos.
ls("package:magrittr") %>%
 str_subset("^[^%]*$")
```

```
[1] "add" "and"
[3] "debug_fseq" "debug_pipe"
[5] "divide_by" "divide_by_int"
[7] "equals" "extract"
[9] "extract2" "freduce"
[11] "functions" "inset"
[13] "inset2" "is_greater_than"
[15] "is_in" "is_less_than"
[17] "is_weakly_greater_than" "is_weakly_less_than"
[19] "mod" "multiply_by"
[21] "multiply_by_matrix" "n'est pas"
[23] "not" "or"
[25] "raise_to_power" "set_colnames"
[27] "set_names" "set_rownames"
[29] "subtract" "undebug_fseq"
[31] "use_series"
```

# Exemplos do uso do pipe (1)

---

```
x <- precip
mean(sqrt(x - min(x)))
```

1  
2

```
[1] 5.020078
```

---

```
x <- x - min(x)
x <- sqrt(x)
mean(x)
```

1  
2  
3

```
[1] 5.020078
```

---

```
precip %>%
 `-(min(.))` %>% # o mesmo que subtract(min(.))
 sqrt() %>%
 mean()
```

1  
2  
3  
4

```
[1] 5.020078
```

## Exemplos de uso do pipe (2)

```
x <- precip
x <- sqrt(x)
x <- x[x > 5]
x <- mean(x)
x
```

```
[1] 6.364094
```

```
precip %>%
 sqrt() %>%
 .[is_greater_than(., 5)] %>% # o mesmo que .[`>`(., 5)]
 mean()
```

```
[1] 6.364094
```

1  
2  
3  
4  
5

1  
2  
3  
4



Mãos à obra!

# Instalar o tidyverse

---

```
Do CRAN.
install.packages("tidyverse")

Do GitHub.
install.packages("devtools")
devtools::install_github("hadley/tidyverse")

Atualizar caso já tenha instalado.
tidyverse_update()
```

---

# O que vem agora?

- ▶ Uma visão aprofundada de cada pacote do tidyverse.
- ▶ Exemplos didáticos seguidos de desafios práticos.
- ▶ *Happy coding.*

# Referências

TEUTONICO, D. **Ggplot2 essentials.** Packt Publishing, 2015.

WICKHAM, H. **Ggplot2: Elegant graphics for data analysis.** Springer International Publishing, 2016.

WILKINSON, L.; WILLS, D.; ROPE, D.; NORTON, A.; DUBBS, R. **The grammar of graphics.** Springer New York, 2013.